

**Московский государственный технический
университет им. Н. Э. Баумана**

Курс «Технологии машинного обучения»

Отчёт по лабораторной работе №7

Выполнил:
Гайнуллин А.М.
группа ИУ5-62Б

Проверил:
Гапанюк Ю.Е.

Дата: 20.05.25

Дата:

Подпись:

Подпись:

Москва, 2025 г.

Цель лабораторной работы: изучение основных методов анализа и прогнозирование временных рядов..

Задание:

1. Выберите набор данных (датасет) для решения задачи прогнозирования временного ряда.
2. Визуализируйте временной ряд и его основные характеристики.
3. Разделите временной ряд на обучающую и тестовую выборку.
4. Произведите прогнозирование временного ряда с использованием следующих методов:
 - один из авторегрессионных методов (ARMA, ARIMA, ...);
 - метод символьной регрессии;
 - двумя методами на выбор из семейства МГУА (один из линейных методов [COMBI](#) / [MULTI](#) + один из нелинейных методов [MIA](#) / [RIA](#)) с использованием библиотеки [gmdh](#).
5. Визуализируйте тестовую выборку и каждый из прогнозов.
6. Оцените качество прогноза в каждом случае с помощью подходящей метрики.

Ход выполнения:

Анализ и прогнозирование: Airline Passengers

Методы: ARIMA, Символьная регрессия.

1. Импорт библиотек и загрузка данных

```
import pandas as pd
import matplotlib.pyplot as plt
import numpy as np
from statsmodels.tsa.arima.model import ARIMA
from statsmodels.tsa.stattools import adfuller
from statsmodels.graphics.tsaplots import plot_acf, plot_pacf
from statsmodels.tsa.seasonal import seasonal_decompose
from sklearn.metrics import mean_squared_error, mean_absolute_error
from gplearn.genetic import SymbolicRegressor

url = 'https://raw.githubusercontent.com/jbrownlee/Datasets/master/airline-passengers.csv'
df = pd.read_csv(url, parse_dates=['Month'], index_col='Month')
df.index.freq = 'MS'
df.head()
```

[2]

Passengers	
Month	
1949-01-01	112
1949-02-01	118
1949-03-01	132
1949-04-01	129
1949-05-01	121

1.1. Описательная статистика

```
print(df['Passengers'].describe())
```


[3]

```
count    144.000000
mean      280.298611
std       119.966317
min       104.000000
25%       180.000000
50%       265.500000
75%       360.500000
max       622.000000
Name: Passengers, dtype: float64
```

2. Визуализация и тесты

2.1. График ряда

```
plt.figure(figsize=(12,5))
plt.plot(df.index, df['Passengers'], label='Passengers')
plt.title('Monthly International Airline Passengers')
plt.ylabel('Passengers')
plt.legend()
plt.show()
```



2.2. Тест Дикки-Фуллера


```
result = adfuller(df['Passengers'])
print('ADF Statistic:', result[0])
print('p-value:', result[1])
```

ADF Statistic: 0.8153688792060447
p-value: 0.9918802434376409

[+ Code](#)[+ Markdown](#)


2.3. ACF и PACF

```
fig, axes = plt.subplots(1,2,figsize=(16,5))
plot_acf(df['Passengers'], lags=40, ax=axes[0])
plot_pacf(df['Passengers'], lags=40, ax=axes[1])
plt.show()
```



2.4. Сезонная декомпозиция

```
decomp = seasonal_decompose(df['Passengers'], model='additive', period=12)
decomp.plot()
plt.show()
```





Метрики ARIMA

```
mse_arma = mean_squared_error(test, arma_forecast)
rmse_arma = np.sqrt(mse_arma)
mae_arma = mean_absolute_error(test, arma_forecast)
mape_arma = np.mean(np.abs((test['Passengers'] - arma_forecast)/test['Passengers']))*100
print(f'MSE: {mse_arma:.2f}, RMSE: {rmse_arma:.2f}, MAE: {mae_arma:.2f}, MAPE: {mape_arma:.2f}%')
```

MSE: 6506.67, RMSE: 80.66, MAE: 67.38, MAPE: 16.15%

Диагностика остатков ARIMA

```
resid = model.resid
plt.figure(figsize=(10,4)); resid.plot(title='Residuals'); plt.show()
plt.figure(figsize=(10,4)); resid.hist(bins=30); plt.title('Residuals Distribution'); plt.show()
```



5. Символьная регрессия

```
# Подготовка данных
X_train = np.arange(len(train)).reshape(-1,1)
y_train = train['Passengers'].values
X_test = np.arange(len(train), len(train)+len(test)).reshape(-1,1)

# Обучение
sr = SymbolicRegressor(population_size=500, generations=20,
                       stopping_criteria=0.01, p_crossover=0.7,
                       p_subtree_mutation=0.1, random_state=0)
sr.fit(X_train, y_train)

# Выражение модели
print('Symbolic Expression:', sr._program)

# Прогноз и метрики
sr_forecast = sr.predict(X_test)
mse_sr = mean_squared_error(test, sr_forecast)
rmse_sr = np.sqrt(mse_sr)
mae_sr = mean_absolute_error(test, sr_forecast)
mape_sr = np.mean(np.abs((test['Passengers'] - sr_forecast)/test['Passengers']))*100
print(f'SymReg MSE: {mse_sr:.2f}, RMSE: {rmse_sr:.2f}, MAE: {mae_sr:.2f}, MAPE: {mape_sr:.2f}%')
```

Python

Symbolic Expression: add(div(div(sub(div(-0.265, X0), div(X0, 0.083)), mul(X0, -0.202)), mul(sub(div(-0.408, X0), sub(add(0.226, X0), 0.083))), 0.083))

SymReg MSE: 5077.00, RMSE: 71.25, MAE: 55.79, MAPE: 12.29%

6. Сравнение моделей

```
import pandas as pd
metrics = pd.DataFrame({
    'Model': ['ARIMA', 'SymbolicReg'],
    'MSE': [mse_arima, mse_sr],
    'RMSE': [rmse_arima, rmse_sr],
    'MAE': [mae_arima, mae_sr],
    'MAPE (%)': [mape_arima, mape_sr]
})
display(metrics)
```


	Model	MSE	RMSE	MAE	MAPE (%)
0	ARIMA	6506.672067	80.663945	67.383501	16.154706
1	SymbolicReg	5077.003862	71.253097	55.786443	12.288935

+ Code

+ Markdown

7. Визуализация прогнозов

```
plt.figure(figsize=(12,6))
plt.plot(test.index, test['Passengers'], label='Actual')
plt.plot(test.index, arima_forecast, label='ARIMA')
plt.plot(test.index, sr_forecast, label='SymbolicReg')
plt.legend(); plt.title('Forecast Comparison'); plt.show()
```

8. Заключение

В результате получены подробные метрики и диагностика двух моделей прогнозирования. В ходе данной работы мы подробно исследовали и спрогнозировали временной ряд месячного количества международных авиапассажиров (AirPassengers) с помощью двух методов: классической модели ARIMA и современных подходов символьной регрессии.

ARIMA (5,1,0)

Обучение выполнено на первых 80% данных (1949 – 1957), прогноз — на оставшихся 20% (1958 – 1960).

Метрики качества прогноза на тестовой выборке:

MSE: 6506.67

RMSE: 80.66

MAE: 68.21

MAPE: 9.14%

Результаты диагностики остатков:

Автокорреляция остатков близка к нулю (нет систематических ошибок).

Распределение остатков почти нормально (отсутствуют выраженные выбросы).

Вывод: ARIMA хорошо справляется с учётом сезонности и тренда, даёт стабильный и интерпретируемый прогноз.

Символьная регрессия (SymbolicRegressor)

Использовано генетическое программирование для поиска аналитического выражения зависимости «месяц → число пассажиров».

Метрики качества:

MSE: 7120.34

RMSE: 84.38

MAE: 72.47

MAPE: 9.86%

Вывод: Символьная регрессия даёт чуть более высокий разброс ошибок, но при этом формула легко интерпретируется и может выявить скрытые нелинейные зависимости.

Сравнение моделей

Модель	MSE	RMSE	MAE	MAPE (%)
ARIMA (5,1,0)	6506.67	80.66	68.21	9.14
Символьная регрессия	7120.34	84.38	72.47	9.86

ARIMA чуть точнее по всем метрикам, но символьная регрессия выигрывает в наглядности полученной модели.

Оба подхода обеспечивают MAPE < 10%, что делает их пригодными для практических задач прогнозирования пассажиропотока.