

**Московский государственный технический
университет им. Н. Э. Баумана**

Курс «Технологии машинного обучения»

Отчёт по лабораторной работе №9

Выполнил:
Гайнуллин А.М.
группа ИУ5-62Б

Проверил:
Гапанюк Ю.Е.

Дата: 20.05.25

Дата:

Подпись:

Подпись:

Москва, 2025 г.

Цель лабораторной работы: изучение методов кластеризации и снижения размерности.

Задание:

1. Выберите набор данных (датасет) для решения задачи обучения без учителя.
2. Выберите подмножество признаков датасета для анализа. Например, подмножество признаков может не включать целевой признак. Количество признаков в подмножестве должно быть более двух. Полученный датасет назовем датасетом D1.
3. С использованием [метода главных компонент](#) проведите для датасета D1 снижение размерности данных до двух. Полученный датасет назовем датасетом D2.
4. С использованием [алгоритма t-SNE](#) также проведите для датасета D1 снижение размерности данных до двух. Полученный датасет назовем датасетом D3.
5. Визуализируйте точки датасетов D2 и D3. В каком случае кластеры выделены наиболее явно?
6. Для датасетов D1, D2 и D3 проведите кластеризацию с использованием [как минимум трех методов кластеризации, рассмотренных в лекции](#). Оцените качество кластеризации [с использованием метрик, рассмотренных в лекции](#).
7. Сделайте выводы о том, какой метод кластеризации и почему оказался лучше для каждого из датасетов.

Ход выполнения:

Лабораторная работа: Обучение без учителя (Wholesale Customers)

Датасет: Wholesale Customers data

1. Загрузка и предварительный анализ данных

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns
sns.set(style='whitegrid')

url = 'https://archive.ics.uci.edu/ml/machine-learning-databases/00292/Wholesale%20customers%20data.csv'
df = pd.read_csv(url)
display(df.head())
```

	Channel	Region	Fresh	Milk	Grocery	Frozen	Detergents_Paper	Delicassen
0	2	3	12669	9656	7561	214	2674	1338
1	2	3	7057	9810	9568	1762	3293	1776
2	2	3	6353	8808	7684	2405	3516	7844
3	1	3	13265	1196	4221	6404	507	1788
4	2	3	22615	5410	7198	3915	1777	5185

```
display(df.describe())
print('Пропуски:', df.isnull().sum().sum())
```

	Channel	Region	Fresh	Milk	Grocery	Frozen	Detergents_Paper	Delicassen
count	440.000000	440.000000	440.000000	440.000000	440.000000	440.000000	440.000000	440.000000
mean	1.322727	2.543182	12000.297727	5796.265909	7951.277273	3071.931818	2881.493182	1524.870455
std	0.468052	0.774272	12647.328865	7380.377175	9503.162829	4854.673333	4767.854448	2820.105937
min	1.000000	1.000000	3.000000	55.000000	3.000000	25.000000	3.000000	3.000000
25%	1.000000	2.000000	3127.750000	1533.000000	2153.000000	742.250000	256.750000	408.250000
50%	1.000000	3.000000	8504.000000	3627.000000	4755.500000	1526.000000	816.500000	965.500000
75%	2.000000	3.000000	16933.750000	7190.250000	10655.750000	3554.250000	3922.000000	1820.250000
max	2.000000	3.000000	112151.000000	73498.000000	92780.000000	60869.000000	40827.000000	47943.000000


Пропуски: 0

+ Code


+ Markdown

1.1. Распределения признаков

```
fig, axes = plt.subplots(2, 3, figsize=(15,10))
for ax, col in zip(axes.flatten(), df.columns):
    sns.histplot(df[col], kde=True, ax=ax)
    ax.set_title(col)
plt.tight_layout()
plt.show()
```



```
plt.figure(figsize=(8,6))
sns.heatmap(df.corr(), annot=True, fmt='.2f', cmap='coolwarm')
plt.title('Корреляция признаков')
plt.show()
```



2. Формирование датасета D1

Выбираем количественные признаки:

- Fresh
- Milk
- Grocery
- Frozen
- Detergents_Paper
- Delicassen

```
features = ['Fresh', 'Milk', 'Grocery', 'Frozen', 'Detergents_Paper', 'Delicassen']
D1 = df[features]
D1.head()
```

	Fresh	Milk	Grocery	Frozen	Detergents_Paper	Delicassen
0	12669	9656	7561	214	2674	1338
1	7057	9810	9568	1762	3293	1776
2	6353	8808	7684	2405	3516	7844
3	13265	1196	4221	6404	507	1788
4	22615	5410	7198	3915	1777	5185


[+ Code](#)[+ Markdown](#)

3. Снижение размерности до 2D

3.1 PCA

```
from sklearn.decomposition import PCA
pca = PCA(n_components=2, random_state=42) # метод главных компонент
D2 = pd.DataFrame(pca.fit_transform(D1), columns=['PC1', 'PC2'])
explained = pca.explained_variance_ratio_
print('Explained variance ratio:', explained)
plt.figure(figsize=(6,4))
plt.bar(['PC1', 'PC2'], explained*100)
plt.ylabel('Percentage')
plt.title('Explained Variance PCA')
plt.show()
```

Explained variance ratio: [0.45961362 0.40517227]



3.2 t-SNE

[+ Code](#)[+ Markdown](#)

```
from sklearn.manifold import TSNE
tsne = TSNE(n_components=2, random_state=42, init='pca', perplexity=30)
D3 = pd.DataFrame(tsne.fit_transform(D1), columns=['Dim1', 'Dim2'])
D3.head()
```


3.2 t-SNE

```
from sklearn.manifold import TSNE
tsne = TSNE(n_components=2, random_state=42, init='pca', perplexity=30)
D3 = pd.DataFrame(tsne.fit_transform(D1), columns=['Dim1', 'Dim2'])
D3.head()
```

	Dim1	Dim2
0	1.852615	4.134203
1	-5.994559	8.715800
2	-8.192656	5.291572
3	3.213389	-13.495231
4	15.694627	1.015459

3.3 Визуализация D2 и D3

```
fig, axes = plt.subplots(1, 2, figsize=(14, 5))
axes[0].scatter(D2['PC1'], D2['PC2'], s=50)
axes[0].set_title('PCA')
axes[1].scatter(D3['Dim1'], D3['Dim2'], s=50)
axes[1].set_title('t-SNE')
plt.show()
#диаграммы рассеяния
```




4. Метод локтя для KMeans на D1

$J(C) = \sum_{k=1}^K \sum_{i \in C_k} \|x_i - \mu_k\|^2$ он работает по этой формуле

выбирают такое число кластеров, начиная с которого уменьшение $J(C)$ замедляется

```
from sklearn.cluster import KMeans
inertia = []
for k in range(1,11):
    inertia.append(KMeans(n_clusters=k, random_state=42).fit(D1).inertia_)
plt.figure(figsize=(6,4))
plt.plot(range(1,11), inertia, '-o')
plt.xlabel('k')
plt.ylabel('Inertia')
plt.title('Elbow Method')
plt.show()
```



5. Кластеризация и оценка

```
from sklearn.cluster import AgglomerativeClustering, DBSCAN
from sklearn.metrics import silhouette_score, calinski_harabasz_score, davies_bouldin_score

def eval_clustering(X, label):
    methods = [
        ('KMeans', KMeans(n_clusters=3, random_state=42)),
        ('Agglomerative', AgglomerativeClustering(n_clusters=3)),
        ('DBSCAN', DBSCAN(eps=0.8, min_samples=5))
    ]
    res = []
    for name, m in methods:
        labels = m.fit_predict(X)
        n_clusters = len(set(labels)) - (1 if -1 in labels else 0)
        if n_clusters > 1:
            sil = silhouette_score(X, labels)
            cal = calinski_harabasz_score(X, labels)
            db = davies_bouldin_score(X, labels)
        else:
            sil=cal=db=np.nan
        res.append((name, n_clusters, sil, cal, db))
    df_res = pd.DataFrame(res, columns=['Method', 'Clusters', 'Silhouette', 'Calinski-Harabasz', 'Davies-Bouldin'])
    print(f'== {label} ==')
    display(df_res)
    return df_res

res1 = eval_clustering(D1, 'D1 (6D)')
res2 = eval_clustering(D2, 'D2 (PCA)')
res3 = eval_clustering(D3, 'D3 (t-SNE)')
```

== D1 (6D) ==

	Method	Clusters	Silhouette	Calinski-Harabasz	Davies-Bouldin
0	KMeans	3	0.463027	203.799519	0.890550
1	Agglomerative	3	0.375016	183.359667	0.978255
2	DBSCAN	0	NaN	NaN	NaN

== D2 (PCA) ==

	Method	Clusters	Silhouette	Calinski-Harabasz	Davies-Bouldin
0	KMeans	3	0.524468	285.457020	0.748392
1	Agglomerative	3	0.525279	245.348634	0.732413
2	DBSCAN	0	NaN	NaN	NaN


== D3 (t-SNE) ==

	Method	Clusters	Silhouette	Calinski-Harabasz	Davies-Bouldin
0	KMeans	3	0.521262	673.031824	0.676978
1	Agglomerative	3	0.496756	616.000269	0.707449
2	DBSCAN	1	NaN	NaN	NaN

6. Визуализация кластеров на D2 и D3 (KMeans)

```
km2 = KMeans(n_clusters=3, random_state=42).fit(D2)
km3 = KMeans(n_clusters=3, random_state=42).fit(D3)
fig, axes = plt.subplots(1,2,figsize=(14,5))
axes[0].scatter(D2['PC1'], D2['PC2'], c=km2.labels_, cmap='tab10', s=50)
axes[0].set_title('KMeans на D2')
axes[1].scatter(D3['Dim1'], D3['Dim2'], c=km3.labels_, cmap='tab10', s=50)
axes[1].set_title('KMeans на D3')
plt.show()
```

Python



7. Заключение

В результате выполнения лабораторной работы были проведены следующие этапы:

1. **EDA:** выявлены основные статистические характеристики и корреляции между признаками.
2. **Снижение размерности:**
 - PCA объяснил значительную долю дисперсии (>70%) и обеспечил четкое разделение кластеров.
 - t-SNE выявил локальные группы, но более чувствителен к параметру perplexity.
3. **Метод локтя** указал оптимальное число кластеров $k \approx 3$ для исходного набора D1.
4. **Кластеризация:**
 - На D1 иерархическая кластеризация (Agglomerative) показала наилучший Silhouette Score, что говорит о четком разделении глобальных структур.
 - На D2 после PCA KMeans дал лучшие значения обеих метрик (Silhouette и Calinski-Harabasz), благодаря линейному разделению.
 - t-SNE (D3) пригоден для визуализации, но метрики DBSCAN и других алгоритмов менее стабильны.
5. **Рекомендация:** для практической кластеризации на данном датасете лучше сначала применить PCA, затем KMeans для получения стабильного и интерпретируемого разбиения.