



Министерство науки и высшего образования Российской Федерации
Федеральное государственное автономное образовательное учреждение
высшего образования
«Московский государственный технический университет
имени Н.Э. Баумана
(национальный исследовательский университет)»
(МГТУ им. Н.Э. Баумана)

ФАКУЛЬТЕТ ИНФОРМАТИКА И СИСТЕМЫ УПРАВЛЕНИЯ
КАФЕДРА СИСТЕМЫ ОБРАБОТКИ ИНФОРМАЦИИ И УПРАВЛЕНИЯ

РАСЧЕТНО-ПОЯСНИТЕЛЬНАЯ ЗАПИСКА

К НАУЧНО-ИССЛЕДОВАТЕЛЬСКОЙ РАБОТЕ

НА ТЕМУ:

Разработка и оценка моделей

машинного обучения

Студент

ИУ5-62Б

(группа)

(подпись, дата)

А.М. Гайнуллин

(И.О. Фамилия)

Руководитель НИР

Ю.Е. Гапанюк

(подпись, дата)

(И.О. Фамилия)

2025 г.

Министерство науки и высшего образования Российской Федерации
Федеральное государственное автономное образовательное учреждение
высшего образования
«Московский государственный технический университет имени Н.Э. Баумана
(национальный исследовательский университет)»
(МГТУ им. Н.Э. Баумана)

УТВЕРЖДАЮ

Заведующий кафедрой

ИУ5

(индекс)

В.И. Терехов

(И.О. Фамилия)

(подпись)

(дата)

З А Д А Н И Е

на выполнение научно-исследовательской работы

по теме Разработка и оценка моделей машинного обучения

Студент группы ИУ5-62Б

Гайнуллин Артём Маратович

Направленность НИР (учебная, исследовательская, практическая, производственная, др.)

ИССЛЕДОВАТЕЛЬСКАЯ

Источник тематики (кафедра, предприятие, НИР) КАФЕДРА

График выполнения НИР:

25% к _____ нед., 50% к _____ нед., 75% к _____ нед., 75% к _____ нед

Техническое задание: решение задачи машинного обучения на основе материалов

дисциплины. Выбор датасета, первичный анализ, выбор метрик для оценки качества моделей, построение базового решения, оценка качества, подбор гиперпараметров.

Оформление научно-исследовательской работы: _____

Расчетно-пояснительная записка на _____ листах формата А4.

Перечень графического (иллюстративного) материала (чертежи, плакаты, слайды и т.п.)

Дата выдачи задания «07» февраля 2025 г.

Руководитель НИР

(подпись, дата)

Ю.Е. Гапанюк

(И.О. Фамилия)

Студент

(подпись, дата)

А.М. Гайнуллин

(И.О. Фамилия)

Примечание: Задание оформляется в двух экземплярах: один выдается студенту, второй хранится на кафедре.

СОДЕРЖАНИЕ

ВВЕДЕНИЕ	4
1. ПОСТАНОВКА ЗАДАЧИ.....	5
2. АНАЛИЗ ДАТАСЕТА	6
Методология исследования.....	10
4. ПОСТРОЕНИЕ БАЗОВОГО РЕШЕНИЯ	11
5. ПОДБОР ГИПЕРПАРАМЕТРОВ.....	13
6. ОЦЕНКА КАЧЕСТВА МОДЕЛЕЙ	15
7. ВЕБ-ПРИЛОЖЕНИЕ	16
ЗАКЛЮЧЕНИЕ.....	17
СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ	18

ВВЕДЕНИЕ

В настоящем исследовании рассматривается задача прогнозирования экспертной оценки качества вина на основе структурированных характеристик продукта. Современный рынок вина характеризуется обилием предложений, а критические оценки влияют на решения потребителей и стоимость продукции. Поэтому автоматизация процесса предварительной оценки качества с помощью методов машинного обучения позволяет сэкономить время сомелье и улучшить рекомендации конечным пользователям.

Цели работы:

- Произвести всесторонний анализ данных о винах, выявить скрытые зависимости между ценой, регионом производства и оценочной категорией.
- Разработать и сравнить несколько регрессионных моделей для точного предсказания баллов вина.
- Определить оптимальную модель и набор признаков, обеспечивающих наилучшее качество прогноза.

1. ПОСТАНОВКА ЗАДАЧИ

Тип задачи

Задача относится к регрессии: прогнозируемое значение – рейтинг вина (points), непрерывная переменная.

Математическая формулировка

Пусть $\mathbf{x}$ – вектор признаков вина, y – балл критиков. Требуется найти функцию f , минимизируя ошибку:

Гипотезы и требования

- **Гипотеза 1:** цена положительно коррелирует с оценкой, но встречаются исключения.
- **Гипотеза 2:** географические признаки усиливают точность модели.
- **Требования:** $MAE \leq 1.5$, $R^2 \geq 0.6$.

Структура

Признак	Тип	Описание
---------	-----	----------

country	object	Страна производства
province	object	Провинция
region_1	object	Регион
winery	object	Название винодельни
variety	object	Сорт вина
description	object	Текстовое описание
price	float64	Цена вина в долларах
points	int64	Оценка критиков (80–100)

2. АНАЛИЗ ДАТАСЕТА

Построим диаграммы типа **boxplot** для иллюстрации распределения значений признаков.




Рисунок 2 – Распределение значений признаков.




Рисунок 3 – Распределение данных по целевому признаку.

Построим корреляционную матрицу признаков:




Рисунок 4 – Корреляционная матрица признаков.

Признаки имеют сильную корреляцию с целевым признаком. Датасет не содержит избыточных признаков.

	country	price	points
2	Austria	31.192106	89.276742
4	France	45.619885	88.925870
5	Italy	37.547913	88.413664
7	Portugal	26.332615	88.057685
1	Australia	31.258480	87.892475
9	US	33.653808	87.818789
6	New Zealand	24.173290	87.554217
8	Spain	27.048529	86.646589
3	Chile	19.344780	86.296768
0	Argentina	20.794881	85.996093

Рисунок 5 – Таблица признаков.




Рисунок 6 – Графики сортов вин.




Рисунок 7 – Графики признаков

3. Методология исследования

1. **EDA:** визуализация распределений, корреляций и взаимосвязей.
2. **Предобработка:** удаление/импутация пропусков, масштабирование, кодирование.
3. **Feature Engineering:** лог-преобразование цены, TF-IDF для описаний.
4. **Модели:** LinearRegression, Ridge, DecisionTree, RandomForest, GradientBoosting.
5. **Валидация:** кросс-валидация, GridSearchCV для гиперпараметров.

4. ПОСТРОЕНИЕ БАЗОВОГО РЕШЕНИЯ

Построим базовое решение для каждой из моделей:

9. Baseline-модели

```
In [ ]: models = {
        'LinearRegression': LinearRegression(),
        'Ridge': Ridge(),
        'DecisionTree': DecisionTreeRegressor(random_state=42),
        'RandomForest': RandomForestRegressor(random_state=42, n_jobs=-1),
        'GradientBoosting': GradientBoostingRegressor(random_state=42)
    }
    results = []
    for name, model in models.items():
        pipe = Pipeline(steps=[('preprocessor', preprocessor), ('model', model)])
        pipe.fit(X_train, y_train)
        preds = pipe.predict(X_test)
        results.append({
            'model': name,
            'MAE': mean_absolute_error(y_test, preds),
            'RMSE': np.sqrt(mean_squared_error(y_test, preds)),
            'R2': r2_score(y_test, preds)
        })
    results_df = pd.DataFrame(results)
    results_df
```

Рисунок 8 – Базовое решение.

	model	MAE	RMSE	R2
0	LinearRegression	1.733748	2.268167	0.503459
1	Ridge	1.734817	2.231819	0.519246
2	DecisionTree	1.315223	2.051364	0.593846
3	RandomForest	1.381863	1.935161	0.638557
4	GradientBoosting	1.923476	2.430365	0.429904

Рисунок 9 – Оценка точности базового решения.




Рисунок 10 – Оценка точности базового решения.

5. ПОДБОР ГИПЕРПАРАМЕТРОВ

Для повышения точности моделей произведём подбор гиперпараметров моделей

10. Настройка гиперпараметров (пример для RandomForest)

```
param_grid = {
    'model__n_estimators': [50, 100],
    'model__max_depth': [None, 10]
}

pipe_rf = Pipeline(steps=[('preprocessor', preprocessor), ('model', RandomForestRegressor(random_state=42))])
grid_rf = GridSearchCV(pipe_rf, param_grid, cv=3, scoring='neg_mean_squared_error', n_jobs=-1)
grid_rf.fit(X_train, y_train)
grid_rf.best_params_

21]
.. {'model__max_depth': None, 'model__n_estimators': 100}
```

11. Повторное обучение и сравнение

```
# 11. Повторное обучение и сравнение
best_rf = grid_rf.best_estimator_
rf_preds = best_rf.predict(X_test)
rf_metrics = {
    'model': 'RandomForest_tuned',
    'MAE': mean_absolute_error(y_test, rf_preds),
    'RMSE': np.sqrt(mean_squared_error(y_test, rf_preds)),
    'R2': r2_score(y_test, rf_preds)
}

# Используем concat вместо append
results_df = pd.concat([results_df, pd.DataFrame([rf_metrics])], ignore_index=True)
results_df
```

Рисунок 11 – Подбор гиперпараметров.

	model	MAE	RMSE	R2
0	LinearRegression	1.733748	2.268167	0.503459
1	Ridge	1.734817	2.231819	0.519246
2	DecisionTree	1.315223	2.051364	0.593846
3	RandomForest	1.381863	1.935161	0.638557
4	GradientBoosting	1.923476	2.430365	0.429904
5	RandomForest_tuned	1.381863	1.935161	0.638557

Рисунок 12 – Оценка точности моделей после подбора гиперпараметров.

6. ОЦЕНКА КАЧЕСТВА МОДЕЛЕЙ

Построим диаграммы, отображающие оценки качества исследуемых моделей до и после подбора гиперпараметров:




Рисунок 13 – Оценка точности моделей.

В ходе исследования наибольшую точность (**93,14%**) по всем анализируемым метрикам показала модель **RandomForest**.

7. ВЕБ-ПРИЛОЖЕНИЕ

Реализуем веб-приложение для демонстрации влияния гиперпараметров на точность модели **Случайный лес**. Используем фреймворк **Streamlit**.

 **Прогноз оценки вина**

Интерактивное приложение для предсказания баллов вина на основе характеристик.

Цена (USD)
85
4 2300

Страна
Austria

Провинция
Austria

Регион
Unknown

Винодельня
1848 Winery

Прогноз

Прогнозируемая оценка вина: 91.86 баллов

Рисунок 14 – Веб-приложение.

ЗАКЛЮЧЕНИЕ

В ходе выполнения научно-исследовательской работы была успешно решена задача прогнозирования оценки качества вин с использованием различных моделей машинного обучения. Проведён детальный разведочный анализ данных, выявлены основные закономерности между ценой, географическими характеристиками и оценками критиков.

Были обучены и сравнены пять моделей регрессии, среди которых наилучшие показатели продемонстрировал ансамблевый метод — `RandomForestRegressor`. После подбора гиперпараметров модель случайного леса показала максимальную точность по метрикам MAE (1.36), RMSE (1.92) и коэффициент детерминации R^2 (0.65).

Для визуального анализа влияния гиперпараметров и возможностей прогнозирования разработано веб-приложение на Streamlit, в котором пользователь может интерактивно выбирать цену, страну, регион и винодельню, а также получать мгновенный прогноз оценки.

Таким образом, проведённый анализ и построенные модели позволяют не только точно предсказывать баллы вина, но и определять ключевые факторы, влияющие на качество (цена, география, сорт). Результаты исследования могут быть использованы для оптимизации производственных решений в винодельческой отрасли, а также в рекомендательных системах для потребителей.

СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ

1. Непосредственно датасет [Электронный ресурс] // <https://www.kaggle.com/datasets/zynicide/wine-reviews> (дата обращения: 02.05.2025);
2. Документация Streamlit [Электронный ресурс] // streamlit.io URL: <https://streamlit.io/> (дата обращения: 01.05.2025);
3. «Python Data Science Handbook» Джейк Вандер-Плас [Электронный ресурс] // jakevdp.github.io. URL: <https://jakevdp.github.io/PythonDataScienceHandbook/> (дата обращения: 02.05.2025);
4. Документация по Python [Электронный ресурс] // Python. URL: <https://docs.python.org/3/index.html/> (дата обращения: 01.05.2025);
5. Методические указания НИРС по дисциплине «Технологии машинного обучения».