

**Московский государственный технический
университет им. Н. Э. Баумана**

Курс «Технологии машинного обучения»

Отчёт по рубежному контролю №1

Вариант 3

Выполнил:
Гайнуллин А.М.
группа ИУ5-62Б

Проверил:
Гапанюк Ю.Е.

Дата: 20.04.25

Дата:

Подпись:

Подпись:

Москва, 2025 г.

РК1 по дисциплине Технологии машинного обучения

Гайнуллин А.М. ИУ5-62Б Вариант 3

Задание: Для заданного набора данных проведите корреляционный анализ. В случае наличия пропусков в данных удалите строки или колонки, содержащие пропуски. Сделайте выводы о возможности построения моделей машинного обучения и о возможном вкладе признаков в модель.

Дополнительное задание: для произвольной колонки данных построить гистограмму

Датасет: <https://www.kaggle.com/carolelepelaars/toy-dataset>

```
[ ]: import pandas as pd
import numpy as np
import seaborn as sns
import matplotlib.pyplot as plt
%matplotlib inline
```

```
[ ]: #Загрузка данных
df = pd.read_csv('toy_dataset.csv')
df.head()
```

```
[ ]: 
```

	Number	City	Gender	Age	Income	Illness
0	1	Dallas	Male	41	40367.0	No
1	2	Dallas	Male	54	45084.0	No
2	3	Dallas	Male	42	52483.0	No
3	4	Dallas	Male	40	40941.0	No
4	5	Dallas	Male	46	50289.0	No

```
: #Анализ и удаление пропусков
print('Количество пропусков в каждом столбце:')
print(df.isnull().sum())

# Удалим строки с пропусками
df_clean = df.dropna()
print('\nРазмер после удаления пропусков:', df_clean.shape)
```


Количество пропусков в каждом столбце:

```
Number      0
City         0
Gender       0
Age          0
Income       0
Illness      0
dtype: int64
```

Размер после удаления пропусков: (150000, 6)

```
: #Корреляционный анализ
# Выберем числовые признаки
numeric_cols = df_clean.select_dtypes(include=[np.number]).columns
corr_matrix = df_clean[numeric_cols].corr()
plt.figure(figsize=(8, 6))
sns.heatmap(corr_matrix, annot=True, cmap='coolwarm')
plt.title('Корреляционная матрица')
plt.show()

corr_matrix
```



```
] :
      Number    Age    Income
Number  1.000000 -0.003448  0.410460
Age     -0.003448  1.000000 -0.001318
Income  0.410460 -0.001318  1.000000
```

Выводы:

- Признаки `Age` и `Income` имеют -0.0013 корреляцию.
- Признак `Number` служит только идентификатором и не вносит полезной информации.
- Для машинного обучения можно использовать признаки `Age`, `Income` и закодированный `Illness`.
- Необходимо закодировать категориальные признаки (например, `Gender`, `City`, `Illness`) перед обучением.

```
] : #Пример кодирования категориального признака
df_ml = df_clean.copy()
df_ml['Illness_encoded'] = df_ml['Illness'].map({'No': 0, 'Yes': 1})
df_ml.head()
```

```
] :
   Number  City  Gender  Age  Income  Illness  Illness_encoded
0        1  Dallas   Male   41  40367.0    No                0
1        2  Dallas   Male   54  45084.0    No                0
2        3  Dallas   Male   42  52483.0    No                0
3        4  Dallas   Male   40  40941.0    No                0
4        5  Dallas   Male   46  50289.0    No                0
```

Вывод о моделировании:

- После подготовки данных (удаления пропусков и кодирования) можно применять модели, такие как линейная регрессия, решающие деревья и т.д.
- Наиболее вклад будут вносить `Income` и `Age`, а также закодированный `Illness`. Категориальные признаки `City` и `Gender` можно добавить через One-Hot Encoding.

```
] : # Дополнительное задание: Гистограмма для столбца 'Age'
plt.figure(figsize=(8, 4))
plt.hist(df_clean['Age'], bins=20)
plt.xlabel('Age')
plt.ylabel('Количество')
plt.title('Гистограмма распределения возраста')
plt.show()
```

