

**Московский государственный технический
университет им. Н. Э. Баумана**

Курс «Технологии машинного обучения»

Отчёт по рубежному контролю №2

Вариант 3

Выполнил:
Гайнуллин А.М.
группа ИУ5-62Б

Проверил:
Гапанюк Ю.Е.

Дата: 20.04.25

Дата:

Подпись:

Подпись:

Москва, 2025 г.

Рубежный контроль №2 Гайнуллин А.М. ИУ5-62Б

Методы построения моделей машинного обучения.

Задание. Для заданного набора данных (по Вашему варианту) постройте модели классификации или регрессии (в зависимости от конкретной задачи, рассматриваемой в наборе данных). Для построения моделей используйте методы 1 и 2 (по варианту для Вашей группы). Оцените качество моделей на основе подходящих метрик качества (не менее двух метрик). Какие метрики качества Вы использовали и почему? Какие выводы Вы можете сделать о качестве построенных моделей? Для построения моделей необходимо выполнить требуемую предобработку данных: заполнение пропусков, кодирование категориальных признаков, и т.д.

Методы: 1 - Метод опорных векторов, 2 - Случайный лес.

Датасет: <https://www.kaggle.com/datasets/altavish/boston-housing-dataset>

```
] : import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns
%matplotlib inline
from sklearn.model_selection import train_test_split
from sklearn.preprocessing import StandardScaler
from sklearn.svm import SVR
from sklearn.ensemble import RandomForestRegressor
from sklearn.metrics import mean_absolute_error, mean_squared_error, r2_score
```

1. Загрузка данных

Используем датасет Boston Housing из CSV-файла.

```
df = pd.read_csv('BostonHousing.csv')
df.head()
```

	CRIM	ZN	INDUS	CHAS	NOX	RM	AGE	DIS	RAD	TAX	PTRATIO	B	LSTAT	MEDV
0	0.00632	18.0	2.31	0.0	0.538	6.575	65.2	4.0900	1	296	15.3	396.90	4.98	24.0
1	0.02731	0.0	7.07	0.0	0.469	6.421	78.9	4.9671	2	242	17.8	396.90	9.14	21.6
2	0.02729	0.0	7.07	0.0	0.469	7.185	61.1	4.9671	2	242	17.8	392.83	4.03	34.7
3	0.03237	0.0	2.18	0.0	0.458	6.998	45.8	6.0622	3	222	18.7	394.63	2.94	33.4
4	0.06905	0.0	2.18	0.0	0.458	7.147	54.2	6.0622	3	222	18.7	396.90	NaN	36.2

[illegible]

4. Масштабирование признаков

SVR чувствителен к масштабу, масштабируем данные.

```
scaler = StandardScaler()
X_train_scaled = scaler.fit_transform(X_train)
X_test_scaled = scaler.transform(X_test)
```

5. Обучение моделей

```
from sklearn.impute import SimpleImputer

#Импутация пропусков на тренировочной выборке
imputer = SimpleImputer(strategy='median')
X_train_imputed = imputer.fit_transform(X_train)      # обучаем на тренировочных данных
X_test_imputed  = imputer.transform(X_test)          # применяем к тестовым

#Масштабирование (только для SVR)
scaler = StandardScaler()
X_train_scaled = scaler.fit_transform(X_train_imputed)
X_test_scaled  = scaler.transform(X_test_imputed)

#Обучение SVR
svr = SVR(kernel='rbf')
svr.fit(X_train_scaled, y_train)

# Обучение Random Forest
rf = RandomForestRegressor(n_estimators=100, random_state=42)
rf.fit(X_train_imputed, y_train)
```

▼ RandomForestRegressor ⓘ ?

RandomForestRegressor(random_state=42)

6. Оценка качества моделей

Используем метрики:

- R^2 (коэффициент детерминации).
- MAE (Mean Absolute Error).
- RMSE (Root Mean Squared Error).

```
|: #Предсказания
y_pred_svr = svr.predict(X_test_scaled)
y_pred_rf = rf.predict(X_test)

#Функция для вычисления метрик
def evaluate(y_true, y_pred):
    mae = mean_absolute_error(y_true, y_pred)
    rmse = np.sqrt(mean_squared_error(y_true, y_pred))
    r2 = r2_score(y_true, y_pred)
    return mae, rmse, r2

metrics_svr = evaluate(y_test, y_pred_svr)
metrics_rf = evaluate(y_test, y_pred_rf)

#Вывод результатов
results = pd.DataFrame([
    ['SVR'] + list(metrics_svr),
    ['Random Forest'] + list(metrics_rf)
], columns=['Модель', 'MAE', 'RMSE', 'R2'])
results
```

```
/Library/Frameworks/Python.framework/Versions/3.10/lib/python3.10/site-pack
tted without feature names
warnings.warn(
```

```
|:

```

	Модель	MAE	RMSE	R2
0	SVR	2.769549	5.142733	0.639352
1	Random Forest	2.036431	2.905724	0.884866

```


X_imputed_df = pd.DataFrame(X_train_imputed, columns=X.columns)

df_corr = X_imputed_df.copy()
df_corr['MEDV'] = y_train.reset_index(drop=True)

#корреляционная матрица
corr_matrix = df_corr.corr()

plt.figure(figsize=(12, 10))
sns.heatmap(corr_matrix, annot=True, cmap='coolwarm', fmt=".2f", square=True)
plt.title("Корреляционная матрица признаков и целевой переменной (MEDV)")
plt.show()

```



7. Выводы

- Почему выбраны эти метрики?

- R^2 показывает долю дисперсии, объясненную моделью.
- MAE и RMSE дают представление о среднем размере ошибок в тех же единицах, что и целевая переменная.

- Сравнение моделей:

- Если у одной модели выше R^2 и ниже MAE/RMSE, она лучше предсказывает.
- Часто RMSE более чувствителен к крупным ошибкам, MAE — менее.

- Рекомендации:

- Для данной задачи лучше всего себя показала модель случайный лес.
- Для улучшения качества можно подобрать гиперпараметры, добавить новые признаки или использовать другие алгоритмы.